PROYECTO FINAL BIG DATA E IA

La Brecha Digital por Discapacidad en España

Análisis comparativo europeo · Eurostat 2024 · Metodología CRISP-DM

18,26	216	9	3
pp brecha en España	observaciones	países analizados	herramientas clave

SQL · SQLITE · PYTHON · PANDAS · POWER BI · CRISP-DM · K-MEANS CLUSTERING · EUROSTAT 2024 · INCLUSIÓN DIGITAL

Resumen · Abstract

Síntesis ejecutiva del proyecto

ESPAÑA · INTER
SIN DISCAPACID

97,56

Uso de Internet en personas sin discapacidad

ESPAÑA · DISCAPACIDAD SEVERA

79,30

Uso de Internet en personas con discapacidad severa

BRECHA IDENTIFICADA

18,26 p

Diferencia respecto a Países Bajos (1,05 pp): ×17 mayor

Este proyecto analiza la **brecha digital por discapacidad en España** comparada con ocho países europeos y la media UE-27, usando datos oficiales de Eurostat (DSB_ICTIU01, 2024). España presenta una brecha de 18,26 puntos porcentuales, prácticamente idéntica a Italia (18,27 pp), formando el **bloque mediterráneo de mayor exclusión digital**, superado únicamente por Lituania (35,86 pp) y muy por encima de la media europea (12,93 pp).

El análisis identifica una **doble vulnerabilidad** en mujeres con discapacidad severa (73,91%) y en el grupo de 55–74 años (76,85%). Se aplica CRISP-DM usando SQL, Python y Power BI sobre 216 observaciones en 9 entidades × 24 categorías.

Palabras clave: brecha digital, discapacidad, España, Europa, CRISP-DM, clustering K-Means, Big Data, inclusión digital.

01

Introducción

Contexto, preguntas de investigación y objetivos

En España, **casi 1 de cada 5 personas con discapacidad severa no utilizó Internet en 2024**. Esta cifra no refleja un problema de infraestructura —España tiene una de las coberturas de red más completas de Europa— sino una fractura estructural de inclusión digital.

> *¿Cuál es la magnitud real de la brecha digital por discapacidad en España en comparación con sus pares europeos, y qué perfiles sociodemográficos concentran la mayor exclusión digital?*

Preguntas secundarias

P1 ¿En qué posición relativa se sitúa España respecto a Alemania, Francia, Italia, Países Bajos, Portugal, Suecia, Lituania y la media UE-27?

P2 ¿Existe una brecha adicional significativa entre hombres y mujeres dentro del colectivo con discapacidad severa en España?

P3 ¿Qué grupo de edad concentra la mayor exclusión digital entre las personas con discapacidad?

P4 ¿Es posible identificar tipologías diferenciadas de países europeos según su perfil de inclusión digital?

Marco normativo

El proyecto se enmarca en la **Agenda Digital Europa 2030**, la **Estrategia Española sobre Discapacidad 2022–2030** y el **Real Decreto Legislativo 1/2013** (LGDPD). La brecha documentada incumple directamente el espíritu de estos marcos legales.

02

Dataset y Fuente de Datos

Eurostat DSB_ICTIU01 · Estructura, cobertura y calidad

CAMPO	DETALLE
Fuente	Eurostat — Statistical Office of the European Union
Indicador	DSB_ICTIU01 v1.0
Indicador central	I_ILT12 — uso de Internet en los últimos 12 meses
Unidad	PC_IND — porcentaje de individuos
Año	2024 · corte transversal
Países	DE · ES · EU27_2020 · FR · IT · LT · NL · PT · SE
Dimensiones	216 filas × 21 columnas (7 útiles + 14 metadatos)
Licencia	Datos públicos — reutilización libre con atribución a Eurostat

Calidad: flags de baja fiabilidad

El dataset contiene **19 observaciones con flag u** (low reliability, Eurostat). Se excluyen 5 valores nulos en `Y16_24_DIS_SEV` (ES, FR, LT, NL, SE) y se conservan 14 valores con advertencia (`is_reliable=False`), excluidos del clustering.

> *Legalidad: datos abiertos de Eurostat, libre reutilización con atribución. No existe ninguna restricción legal para uso académico.*

03 Metodología CRISP-DM

6 fases aplicadas al análisis de la brecha digital

Se aplica **CRISP-DM** (Cross-Industry Standard Process for Data Mining) porque estructura un proceso analítico completo sobre datos observacionales agregados, desde la definición del problema hasta la presentación de resultados.

FASE 1

Comprensión del negocio

Definir brecha digital por discapacidad. Formular preguntas P1–P4 y objetivos OE1–OE5.

— sin herramienta —

FASE 2

Comprensión de los datos

Explorar DSB_ICTIU01: estructura, flags de calidad, nulos y cobertura geográfica.

Python

FASE 3

Preparación de los datos

Pipeline de limpieza con 9 funciones modulares. Métricas derivadas: gap, pct_vs_eu27.

Python · Pandas

FASE 4

Modelado

EDA, ranking, clustering K-Means (K=3), análisis género y edad. Consultas SQL para P1–P3.

SQL + Python

FASE 5

Evaluación

Validar coherencia de resultados, contrastar con literatura, documentar limitaciones.

Análisis cualitativo

FASE 6

Despliegue

Dashboard interactivo Power BI con 4 páginas, filtros cruzados y narrativa visual.

Power BI

> *Nota metodológica: el análisis es descriptivo-comparativo, no causal. No se puede afirmar que la discapacidad cause menor uso de Internet; sí que se asocia con él en el contexto europeo de 2024.*

04

Herramientas y Tecnologías

Selección justificada para un dataset de 216 observaciones

SQL

SQL · SQLite

Modelo estrella con 7 tablas. Consultas analíticas para P1–P3. Vistas para Power BI.

En lugar de BigQuery: 216 filas y 50 KB no requieren infraestructura distribuida. Queries 100% compatibles.

PY

Python · Pandas · Scikit-learn

Pipeline de limpieza, EDA, K-Means clustering, generación de 10 figuras analíticas.

En lugar de R/Orange: integración nativa con Scikit-learn. Código reproducible y auditable.

PBI

Power BI Desktop

Dashboard de 4 páginas: mapa, ranking, género y edad. Filtros cruzados interactivos.

En lugar de Tableau: gratuito, integración nativa ODBC con SQLite, mismo potencial analítico.

¿Por qué no las demás herramientas del proyecto?

HERRAMIENTA	MOTIVO DE NO INCLUSIÓN
Hadoop / HDFS	Con 216 filas y 50 KB, la infraestructura distribuida no aporta valor. El pipeline Python cubre la ingesta con mayor trazabilidad.
Apache NiFi	El flujo ETL es simple (CSV → limpieza → SQLite). NiFi añadiría complejidad operativa sin beneficio analítico.
Cassandra	Los datos tienen estructura relacional clara. Un modelo estrella SQLite es más apropiado que una base NoSQL.
Orange Data Mining	El clustering se implementa con Scikit-learn: código reproducible, versionable en GitHub.

05

Implementación Práctica

Pipeline, estructura del repositorio y orden de ejecución

Orden de ejecución del pipeline

1. `bash setup.sh` — instalar dependencias Python
2. `python -m cleaning.main` — limpieza (9 funciones modulares → CSV limpio)
3. `python sql_loader.py` — carga CSV limpio en SQLite (modelo estrella)
4. Ejecutar scripts SQL: `04_queries` → `05_queries` → `06_queries`
5. `python clustering_paises.py` — K-Means K=3 con validación elbow + silhouette
6. `python 03_eda.py` — genera 10 figuras analíticas en `images/figures/`
7. Abrir `Estado_de_ES_EU_2024.pbix` · Conectar via ODBC a `proyecto.db`

> *Requisitos: Python 3.11+, SQLite (incluido en Python) y Power BI Desktop (gratuito). Ver `requirements.txt` para las librerías necesarias.*

06

Resultados Principales

Respuestas cuantitativas a las cuatro preguntas de investigación

P1 Ranking europeo por brecha total

POS.	PAÍS	SIN DISCAP.	DISCAP. SEVERA	BRECHA	VS. UE-27	GRUPO
1	LT Lituania	93,31%	57,45%	**35,86 pp**	+22,93	Alta brecha
2	IT Italia	92,88%	74,61%	**18,27 pp**	+5,34	Alta brecha
3 ★	ES España	97,56%	79,30%	**18,26 pp**	+5,33	Alta brecha
—	EU Media UE-27	95,22%	82,29%	*12,93 pp*	ref.	Referencia
4	DE Alemania	95,58%	84,53%	11,05 pp	-1,88	Media
5	FR Francia	96,24%	86,88%	9,36 pp	-3,57	Media
6	PT Portugal	91,73%	84,47%	7,26 pp	-5,67	Media
7	SE Suecia	99,15%	94,43%	4,72 pp	-8,21	Alta inclusión
8	NL Países Bajos	99,72%	98,67%	1,05 pp	-11,88	Alta inclusión

P2 Doble vulnerabilidad de género

Hombres con discapacidad severa · España

83,83%

Mujeres con discapacidad severa · España ← perfil más vulnerable

73,91%

> *España presenta una brecha de género de 9,92 pp dentro del colectivo con discapacidad severa — la mayor del dataset entre países con datos estadísticamente fiables. En la UE-27 esta brecha es de -1,39 pp (las mujeres usan más Internet).*

P3 Intersección edad × discapacidad

GRUPO DE EDAD	% USO INTERNET (DISCAP. SEVERA, ESPAÑA)
25–54 años	82,31%
55–74 años ← perfil más vulnerable	**76,85%**
16–24 años	*No disponible — muestra insuficiente*

El envejecimiento añade **5,46 pp de exclusión adicional** respecto al grupo de 25–54 años. El grupo 55–74 concentra la intersección de dos factores de exclusión: discapacidad y edad avanzada.

P4 Clustering K-Means K=3

GRUPO	PAÍSES	BRECHA MEDIA
Alta inclusión	NL Países Bajos · SE Suecia	~2,9 pp
Inclusión media	DE Alemania · FR Francia · PT Portugal	~9,2 pp

GRUPO	PAÍSES	BRECHA MEDIA
Baja inclusión	ES España · IT Italia · LT Lituania	~24,1 pp

España e Italia comparten cluster, coherente con su práctica igualdad en brecha total (18,26 vs 18,27 pp). La separación entre grupos es clara y estadísticamente validada con elbow + silhouette.

07 Conclusiones

Respuestas a las preguntas de investigación y limitaciones

P1 — Posición europea

España e Italia forman el bloque mediterráneo de mayor exclusión digital (18,26 y 18,27 pp), superando en más de 5 pp la media europea. La brecha no es de conectividad sino de **inclusión diferencial estructural**.

P2 — Doble vulnerabilidad de género

Las mujeres con discapacidad severa usan Internet casi 10 pp menos que los hombres (73,91% vs 83,83%). Es la mayor brecha de género del dataset entre países con datos fiables.

P3 — Intersección edad

El grupo 55–74 años con discapacidad severa (76,85%) concentra la mayor exclusión, sumando dos factores de vulnerabilidad. El envejecimiento añade 5,46 pp de exclusión adicional.

P4 — Tipología de países

El clustering K=3 identifica tres perfiles claros. España e Italia comparten cluster, coherente con su proximidad en todos los indicadores. Países Bajos y Suecia lideran la inclusión.

Limitaciones del estudio

Corte transversal 2024 (sin análisis temporal) · datos agregados, no microdatos · 5 valores no disponibles en `Y16_24_DIS_SEV` · cobertura de 8 países, no representativa de toda la UE · correlaciones descriptivas, no causales.

> *Las conclusiones tienen implicaciones directas de política pública: España necesita intervenciones específicas dirigidas a mujeres con discapacidad severa y al grupo de 55–74 años para reducir su brecha con la media europea.*

08

Bibliografía

Fuentes en formato APA 7

DATOS

Eurostat (2024). *Persons using the internet in the past 12 months by level of disability* [DSB_ICTIU01 v1.0]. Statistical Office of the European Union. https://ec.europa.eu/eurostat/databrowser/view/DSB_ICTIU01

METODOLOGÍA

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

LITERATURA

Dobransky, K., & Hargittai, E. (2006). The disability divide in Internet access and use. *Information, Communication & Society*, *9*(3), 313–334.

LITERATURA

Scheerder, A. J., van Deursen, A. J. A. M., & van Dijk, J. A. G. M. (2017). Determinants of Internet skills, uses and outcomes. *Telematics and Informatics*, *34*(8), 1607–1624.

NORMATIVA

Comisión Europea (2021). Brújula Digital 2030. COM/2021/118. · Gobierno de España (2022). Estrategia Española sobre Discapacidad 2022–2030. · Real Decreto Legislativo 1/2013 (LGDPD). BOE núm. 289.

IA UTILIZADA

Claude (Anthropic, modelo Sonnet) como apoyo en estructuración del pipeline Python, revisión de código SQL y documentación. El contenido analítico, interpretación y conclusiones son responsabilidad de la autora.

09

Anexos

Checklist de entregables · Diccionario de variables

Estado de entregables

- ✓ Práctica en el aula — pipeline funcional y demostrable — 3 pts
- ✓ Repositorio GitHub con estructura navegable por menú — 2 pts
- ✓ Entrega .zip con código, datos y archivos Power BI — 1 pt
- ✓ Informe final (este documento) — 1 pt
- ✓ Redacción, ortografía y bibliografía APA 7 — 1 pt
- → Presentación oral · 15 minutos · storytelling con datos — 2 pts

Diccionario de variables (dataset limpio)

VARIABLE	TIPO	DESCRIPCIÓN
`year`	Int	Año de referencia (2024)
`country_code`	Str	Código ISO del país (ES, DE, ...)
`category_code`	Str	Código ind_type original de Eurostat
`disability_level`	Str	Nivel de discapacidad decodificado
`sex`	Str	Sexo (Total / Female / Male)
`age_group`	Str	Grupo de edad (Total / 16-24 / 25-54 / 55-74)
`pct_internet_use`	Float	% de individuos que usaron Internet [0–100]
`quality_flag`	Str	Flag Eurostat ('u' = baja fiabilidad)

VARIABLE	TIPO	DESCRIPCIÓN
`is_reliable`	Bool	True si el dato es estadísticamente fiable